

ТЕМА 7. СТАТИСТИЧЕСКАЯ ОБРАБОТКА МНОГОМЕРНЫХ ДАННЫХ

Лекция 1. Основы кластер – анализа

Задачей **кластер – анализа** является разделение исходного множества экземпляров многомерных данных на однородные подмножества (кластеры). Поскольку экземпляры данных в многомерном пространстве показателей отображаются точками, то однородность экземпляров, позволяющая объединить их в одно подмножество, может быть выражена расстоянием между этими точками пространства. Единицы измерения и масштабы каждого из показателей отличаются от других показателей, поэтому расстояние в пространстве показателей следует понимать в обобщенном смысле.

Пример. Рассмотрим 5 числовых полей базы данных сотрудников компании: 1) возраст (число полных лет); 2) общий стаж работы; 3) стаж работы в компании; 4) ранг сотрудника по 1-балльной шкале компании; 5) зарплата. Каждая запись в базе относится к одному сотруднику. Ниже приведен фрагмент таблицы из базы данных для 10 сотрудников.

Таблица 1.

№	Возраст, лет	Общий стаж, лет	Стаж в компании, лет	Ранг, баллов	Зарплата, тыс.р.
1	38	20	18	7	80
2	46	31	4	2	30
3	58	41	9	5	45
4	23	1	1	3	35
5	31	14	7	3	40
6	40	18	12	4	40
7	42	19	6	6	45
8	33	15	13	7	90
9	36	16	3	8	100
10	50	32	8	5	60

Каждое поле таблицы (столбец матрицы) – признак. Каждая запись (строка матрицы) – элемент 5-мерного набора выборочных данных из 10 элементов.

Процедура объединения элементов данных в кластеры в кластер – анализе может быть организована по-разному.

Ниже описывается процедура **последовательного кластер – анализа**, в результате которой строится иерархия кластеров разной степени однородности. Процедура включает следующие этапы.

1. Каждый экземпляр данных совпадает с кластером. Число кластеров равно числу экземпляров.
2. Вычисляются расстояния между всеми парами кластеров.
3. Находят два ближайших друг к другу кластера и объединяют их в один кластер. Число кластеров уменьшается на единицу.

4. Определяют расстояния от вновь образованного кластера до остальных кластеров.
5. Возврат к п.3. Повторяют выполнение пп.3-4, пока все кластеры не объединятся в один кластер.

В результате образуется иерархия кластеров, причем каждый из них объединяет экземпляры данных, удаленные друг от друга на расстояния, не превышающие известной величины.

Числовая мера $r(i, j)$, используемая в качестве расстояния между кластерами i и j , должна удовлетворять обычным условиям для расстояний (не отрицательности, симметрии и условию треугольника):

$$\begin{aligned} r(i, j) &\geq 0; \quad r(i, j) = r(j, i); \quad r(i, i) = 0 \\ r(i, j) + r(j, k) &\geq r(i, k), \quad \forall i, j, k \end{aligned}$$

В качестве расстояния чаще всего используют обобщенное евклидово расстояние. Расчет матрицы расстояний между экземплярами выполняется по формулам:

$$\begin{aligned} X &= \|x_{ij}\|, \quad i = 1, \dots, N; \quad j = 1, \dots, n; \quad z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}; \quad \bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_{ij} \\ s_j^2 &= \frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{x}_j)^2; \quad r(i, k) = \sqrt{\sum_{j=1}^n \omega_j (z_{ij} - z_{kj})^2}; \quad 0 \leq \omega_j \leq 1 \end{aligned}$$

В этих формулах x_{ij} – матрица анализируемых многомерных данных. N – число элементов, n – число признаков. ω_j – весовые множители, задающие значимость j -го признака в сравнении с другими признаками.

Для выполнения п.4 процедуры необходимо сформулировать правило определения расстояния между кластерами. Чаще всего применяют одно из трех правил: а) правило «ближайшего соседа»; б) правило «наиболее удаленного соседа»; в) правило «геометрических центров».

По первому правилу за расстояние между двумя кластерами принимают расстояние между наиболее близкими их экземплярами (кластеры близки, если близки хотя бы два их экземпляра).

По второму правилу за расстояние между кластерами принимают расстояние между наиболее удаленными друг от друга экземплярами кластеров (тогда остальные будут еще ближе).

По третьему правилу находят геометрические центры экземпляров каждого из кластеров и за расстояние между кластерами принимают расстояние между этими центрами.

Пример: расстояние между кластерами оценивается по правилу ближайшего соседа.

Пусть множество данных содержит 5 экземпляров. Расстояния между ними вычислены и образуют симметричную матрицу:

$$\mathbf{R} = \begin{vmatrix} 0 & 1,16 & 1,93 & 1,13 & 2,30 \\ & 0 & 1,63 & \underline{0,78} & 1,90 \\ & & 0 & 1,96 & 1,11 \\ & & & 0 & 2,00 \\ & & & & 0 \end{vmatrix}$$

На начальном этапе каждый экземпляр данных образует отдельный кластер. Таким образом, имеется пять кластеров.

№ кластера	1	2	3	4	5	Расстояние
Экземпляры	(1)	(2)	(3)	(4)	(5)	0

Как следует из матрицы, наиболее близкими экземплярами (кластерами) являются 2-й и 4-й (соответствующий элемент матрицы подчеркнут). Объединяем эти экземпляры в один кластер. Получаем следующее распределение экземпляров по классам:

№ кластера	1	2	3	4	Расстояние
Экземпляры	(1)	(2;4)	(3)	(5)	0,78

По правилу ближайшего соседа преобразуем матрицу расстояний между кластерами:

$$\mathbf{R}_1 = \begin{vmatrix} 0 & 1,13 & 1,93 & 2,30 \\ & 0 & 1,63 & 1,90 \\ & & 0 & \underline{1,11} \\ & & & 0 \end{vmatrix}$$

Теперь ближайшими оказываются 3-й и 4-й кластеры. После их объединения приходим к следующей таблице распределения экземпляров по кластерам:

№ кластера	1	2	3	Расстояние
Экземпляры	(1)	(2;4)	(3;5)	1,11

Пересчет матрицы расстояний дает результат

$$\mathbf{R}_2 = \begin{vmatrix} 0 & \underline{1,13} & 1,93 \\ & 0 & 1,63 \\ & & 0 \end{vmatrix}$$

Теперь ближайшими оказываются 1-й и 2-й кластеры с расстоянием 1,13 ед. между ними. Объединение их дает таблицу распределения экземпляров по кластерам:

№ кластера	1	2	Расстояние
Экземпляры	(1;2;4)	(3;5)	1,13

Матрица расстояний между кластерами приобретает вид

$$\mathbf{R}_3 = \begin{vmatrix} 0 & 1,63 \\ & 0 \end{vmatrix}$$

Объединение двух кластеров дает один кластер, объединяющий все экземпляры данных с расстоянием 1,63. Наглядно структуру иерархии кластеров, отображающую степень однородности данных, можно изобразить в виде дерева - дендрограммы (рис.2)




Рис.1. Дерево последовательного кластер-анализа данных

Проведенный анализ позволяет объединять в единый кластер элементы множества данных, задаваясь определенной степенью "близости" элементов.

Автоматизация кластер – анализа в Matlab

Смоделируем трехмерный набор $N = 20$ числовых данных в виде совокупности нормально распределенных случайных чисел с равными среднеквадратическими отклонениями s и разными средними

```
>> X = [normrnd(0,2,20,3);normrnd(10,2,20,3)];
```

Расположение 20 элементов трехмерной выборки в трехмерном пространстве $\{X(1) ; X(2) ; X(3)\}$ построим с помощью команды (рис.2)

```
>> scatter3(X(:,1),X(:,2),X(:,3));
```

Видно, что в рассматриваемом примере множество точек достаточно четко визуально разделено на два подмножества.




Рис.2.

Выполним расчет расстояний между элементами множества с помощью функции

```
>> Y = pdist(X,'minkowski'); % расстояние по Минковскому
```

Некоторые варианты вычисления расстояний между элементами; пользовательский; 'euclidean' ; 'seuclidean' ; 'cityblock' ; 'minkowski' ; 'chebychev' ; 'mahalanobis' ; 'hamming' и другие. С особенностями каждой меры можно ознакомиться в учебных пособиях или из сетевых источников.

Количество парных расстояний равно $(N-1) \cdot N/2$. В нашем примере это 780 (длина вектора Y).

На следующем этапе строится разреженная матрица $(N - 1) \times 3$, состоящая из пар элементов и расстояний между ними

```
>> Z = linkage(Y, 'single');
```

Эта матрица позволяет построить дендрограмму для связей и расстояний между элементами (рис.3)

```
>> [H,T] = dendrogram (Z, 'colorthreshold', 'default', 'orientation', 'right');
>> set (H, 'LineWidth', 2 )
```

Для удобства отображения элементов (по вертикали) и расстояний между ними (по горизонтали) дендрограмма повернута направо, а линии утолщены до 2 единиц. Из графика видно, что множество данных четко распадается на два непересекающихся подмножества.




Рис.3.

Разделение элементов на кластеры осуществляется командой

```
>> T = cluster ( Z, 'maxclust', 2 ); % разделение элементов на два кластера
% цветная диаграмма расположения элементов разных кластеров
% в трехмерном пространстве
figure, scatter3 ( X(:,1), X(:,2), X(:,3), 100, T, 'filled')
```

На рис.4 показаны элементы выборки, окрашенные в соответствии с разделением их на кластеры.

Три функции: `pdist`; `linkage` и `cluster` объединены в одну функцию `clusterdata`. Ее применение позволяет ускорить анализ, хотя и делает его менее гибким. Все применяемые функции имеют много различных опций,

перечисление и разбор которых в рамках одной лекции не представляется возможным.




Рис.4.

Скрипт, объединяющий выполненные действия

```
clear, clc
% генерация 3-хмерной выборки из 20 элементов
X = [normrnd(0,2,20,3);normrnd(10,2,20,3)];
% Распределение элементов выборки в 3-хмерном пр-ве
scatter3(X(:,1),X(:,2),X(:,3));
% вычисление расстояний между парами элементов
Y = pdist(X,'minkowski'); % расстояние по Минковскому
Z = linkage(Y, 'single' ); % матрица связей и расстояний между парами
T = cluster(Z,'maxclust',2); % разделение элементов на два кластера
% цветная диаграмма расположения элементов разных кластеров
% в трехмерном пространстве
figure, scatter3(X(:,1),X(:,2),X(:,3),100,T,'filled')
% дендрограмма расстояний между элементами и связи их в кластеры
figure, [H,T] = dendrogram(Z,'colorthreshold','default','orientation','right');
set(H,'LineWidth',2)
```

Вопросы и задания к теме

1. Изучить использованные функции Matlab. Повторить выполненные в лекции операции при разных опциях функций и проверить роль и влияние этих опций на результаты.
2. Изменить среднеквадратическое отклонение в модельном примере с величины $s = 2$ на $s = 3; 4; 5$. Проследить, как зависят результаты кластер – анализа от величины s .
3. Повторить исследование для других законов распределения данных.
4. Применить кластер – анализ для данных из таблицы 1.